

## Miniproyecto 2 Entrega 1

Natalia Ortiz Vásquez  
202012954  
n.ortizv

María Camila Santamaría  
202015359  
m.santamariaa

Eduardo Herrera Alba  
201912865  
ej.herreraa

### 1. Introducción

Las imágenes médicas extraídas a partir de la resonancia magnética son una de las alternativas tecnológicas no invasivas más importantes de la actualidad, ya que permite obtener imágenes tridimensionales del cuerpo humano sin la necesidad de utilizar radiación. Lo anterior presenta una gran ventaja para el estudio de órganos, tejidos y diagnóstico de enfermedades, especialmente importante en personas con riesgo o sospecha de padecer de algún tipo de cáncer [3].

En este orden de ideas, para el área de la medicina es de vital importancia la mejora en la segmentación de imágenes por medio del procesamiento digital, con el propósito de optimizar y mejorar el diagnóstico, seguimiento y tratamiento de enfermedades y/o patologías [1].

Para este proyecto se utilizó una base de datos que contaba con diversos volúmenes de resonancia magnética del hígado, a la cual se necesitaba realizar segmentación por visión de computador. Sin embargo, luego de la previa exploración de la base de datos, encontramos que el problema de segmentación para esta era de índole desbalanceado, ya que existía una gran diferencia entre la cantidad de píxeles pertenecientes al órgano de interés (el hígado) y todo lo demás, siendo el primero el de menor cantidad de píxeles.

Con base en lo anterior, se decidió no hacer un estudio píxel a píxel, ya que este no sería computacionalmente eficiente debido a la gran cantidad de píxeles que existían y lo desbalanceada que estaba la base de datos. Aunque una opción pudo ser balancear la base de datos, se decidió no hacerlo, ya que al agregar más valores positivos o eliminar algunos negativos estaríamos alterando la naturaleza de la base y por consiguiente la distribución en los volúmenes de la misma.

Por otro lado, previo al desarrollo de la segmentación, se hizo un filtrado de los volúmenes, esto con el propósito de eliminar ruidos de tipo gaussiano y sal y pimienta, el primero de estos siendo el más común en este tipo de imágenes médicas [2].

### 2. Resultados

Después de realizar nuestro modelo de segmentación para el hígado, fundamentado en el pre-procesamiento y técnicas de umbralización para imágenes médicas, se lograron obtener resultados que brindan una comprensión del funcionamiento y la manipulación de imágenes médicas. En primer lugar, se realizó una exploración de la base de datos en la que se observó de qué manera se visualizan las anotaciones proporcionadas en los datos. Para esto se buscó el slice del volumen segmentado que más área de segmentación tiene en el eje axial y se graficó junto a la segmentación del hígado en dicho slice encontrado. Los resultados a lo anterior se pueden observar en la Figura 1. De la misma manera, se realizó un histograma del corte axial del hígado ignorando los valores de intensidad correspondientes al fondo de la imagen médica. Lo anterior se puede observar en la Figura 2.




Figure 1. Corte axial (izquierda) y segmentación (derecha) del hígado.

Teniendo en cuenta el corte axial observado en la figura 1, algunas de las estructuras u órganos del cuerpo pueden ser problemáticos para nuestra metodología de segmentación pues cuentan con intensidades similares a las del hígado. Estos órganos pueden incluir el bazo, los riñones, los vasos sanguíneos y otras estructuras abdominales que cuentan con una similitud en las intensidades.




Figure 2. Corte axial (izquierda) e histograma (derecha) del hígado.

Teniendo en cuenta lo anterior, se estudiaron las imágenes y volúmenes que contuvieran algún tipo de ruido, en este caso, se encontró que los ruidos presentes eran de tipo gaussiano y de tipo sal y pimienta, tal como se observa en la figura 3.

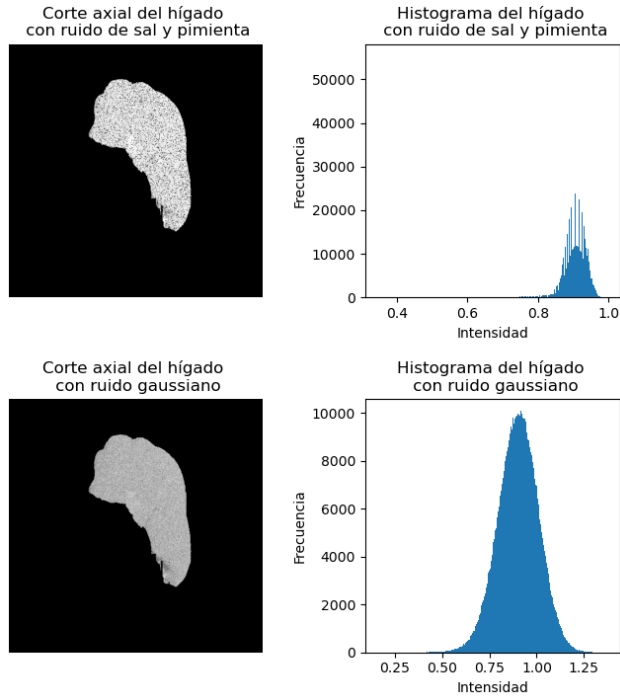


Figure 3. Corte axial del hígado con ruido de sal y pimienta y con ruido gaussiano junto con sus respectivos histogramas.

Del mismo modo, luego de obtener los histogramas obtenidos del volumen original, el corrupto y el filtrado, se observó que el histograma se encuentra desplazado hacia la derecha, más específicamente entre las intensidades de 0.8 a 1.0. Teniendo en cuenta lo anterior, para el volumen original un umbral idóneo sería de 0.8, mientras que para el volumen corrupto con ruido gaussiano, un umbral de 0.65 funcionaría bien. Esto debido a que la mayoría de intensidades del hígado superan esos umbrales de intensidad. Sin em-

bargo, esto se podría traducir en una conservación de ruido, en este caso ruido tipo sal, ya que, se estarían tomando todos los impulsos que superaran el umbral, lo que se puede traducir en un error de segmentación.

Para la remoción de ruido mostrada anteriormente, en primera instancia se decidió filtrar las imágenes por medio de dos filtros lineales, uno gaussiano con  $\sigma$  igual a 3 y otro medio de tamaño 3x3. Sin embargo, como se muestra en la figura 4, el filtro medio no representa un cambio significativo con respecto a la imagen original, mientras que el filtro gaussiano tuvo un mejor desempeño eliminando el ruido gaussiano y en menor medida el ruido impulsivo, lo cual facilita la tarea de segmentación. Sin embargo, generaron una pérdida de la información de la imagen original, es decir, la suavizaron. Lo anterior es un problema si lo que se busca es reconocer alguna patología en el tejido del órgano de interés.

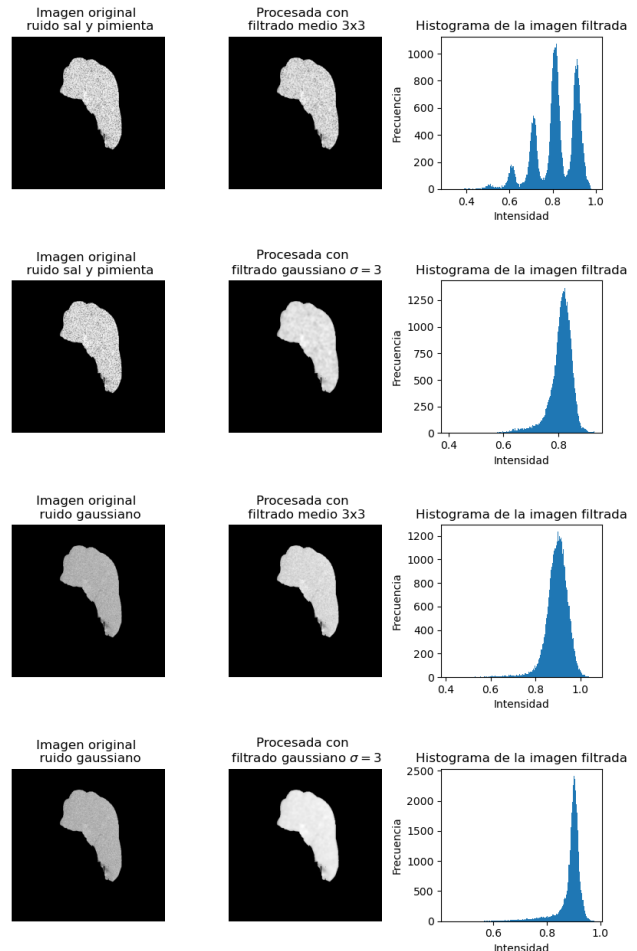


Figure 4. Resultados remoción de ruido utilizando filtrado lineal.

Con base en lo anterior, se decidió experimentar con filtros no lineales, ya que estos se caracterizan por destruir en menor medida la imagen original. Es decir, mantienen

mucha más información de la imagen original. Los resultados obtenidos se observan en la imagen 5. En este caso se aplicó el filtro máximo, mínimo, mediano y mediano adaptativo a los dos tipos de ruido mencionados anteriormente. Respecto a estos resultados se puede observar un rendimiento del filtrado que no es el esperado, esto se debe a la diferencia de intensidades mapeadas en las diferentes secciones del slice. Para el caso del ruido de tipo sal y pimienta, el filtro mediano es el que mejor corrige la imagen por lo que con este, es posible observar de manera clara los diferentes objetos presentes en la imagen médica. Sin embargo, para el mismo tipo de ruido el resto de filtros no logran corregir la imagen de forma adecuada y establecen nuevos valores de intensidades que no se ajustan a la imagen original. Lo anterior se debe a que el ruido de tipo sal y pimienta introduce píxeles con intensidades cercanas a 0 y 1 de manera dispersa en toda la imagen original. Debido a esto, al aplicar los filtros máximo y mínimo se sustituye cada píxel con el valor más alto o más bajo encontrado en su entorno, mientras que al aplicar el filtro mediano se reemplaza cada píxel por el valor que corresponde a la mediana de su vecindario.

Por otro lado, para el ruido de tipo gaussiano se observa que para ciertas secciones de la imagen se ve disminuido el ruido de manera significativa en algunos de los filtros implementados. Sin embargo, para las regiones de la imagen en donde se observan los contrastes no ocurre lo mismo. Analizando todo los filtros de manera visual, se puede concluir que el filtro que realiza la mejor corrección de la imagen es el filtro mediano ya que en este se permite diferenciar de manera más fácil los objetos presentes en la imagen. Lo anterior sucede porque el ruido de tipo gaussiano hace que las intensidades de los objetos se vuelvan bastante similares en sus tonos, lo que complica la distinción entre ellos. Por esta razón, cuando se aplican los filtros de máximo o mínimo, la imagen resultante no es la adecuada, ya que la variación de intensidades en toda la imagen es mínima. A su vez, esto implica que el número de píxeles blancos se ve alterado ligeramente. En consecuencia, se pierde la calidad de la imagen.

Teniendo en cuenta los resultados obtenidos anteriormente para los filtros lineales y no lineales, sería importante realizar filtrados con procesos iterativos de manera que se vea mejorado el filtrado resultante de la imagen original con ruido. Sin embargo, el filtro mediano cumple de manera adecuada con el objetivo del filtrado establecido. De manera específica para el ruido de tipo gaussiano, es importante utilizar filtros que tengan como metodología utilizar las intensidades de los píxeles vecinos, lo que facilitaría de manera significativa la construcción de elementos y, consecuentemente, la diferenciación de los diferentes objetos en la imagen.

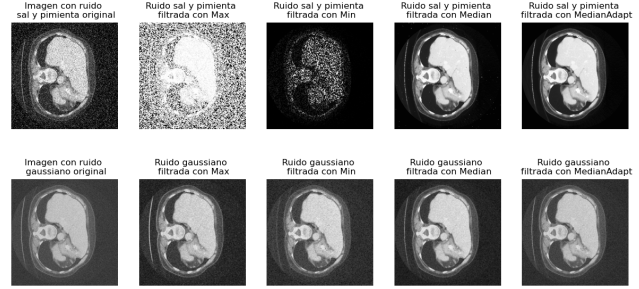


Figure 5. Resultados remoción de ruido utilizado filtrado no lineal.

Con base en los filtros obtenidos anteriormente y para estudiar cuál fue su efectividad, se obtuvo el PSNR correspondiente a cada uno, los resultados se pueden observar en la tabla 1.

Filtro	Ruido	PSNR
Medio	Sal y pimienta	18.0612
Gaussiano	Sal y pimienta	19.7637
Máximo	Sal y pimienta	4.089271
Mínimo	Sal y pimienta	9.31335
Mediano	Sal y pimienta	27.95503
Mediano adaptativo	Sal y pimienta	34.56392
Medio	Gaussiano	10.74856
Gaussiano	Gaussiano	25.143185
Máximo	Gaussiano	15.109375
Mínimo	Gaussiano	15.13644
Mediano	Gaussiano	26.613199
Mediano adaptativo	Gaussiano	22.960706

Table 1. Valores de PSNR de los distintos filtros por cada ruido.

En cuanto a la metodología de evaluación, se procedió al cálculo de las métricas específicas para el modelo de segmentación. En este contexto, se eligió utilizar la métrica de Jaccard 3D en lugar de Jaccard 2D promediado. Esta elección se basa en la naturaleza de los datos con los que se trabaja, que son volúmenes tridimensionales. Aunque ambas métricas comparten una estructura similar en sus fórmulas, Jaccard 3D se diferencia en que considera el volumen tridimensional de los conjuntos en lugar de simplemente el área bidimensional. La distinción clave radica en que, en la métrica de Jaccard 3D, se evalúa la similitud en términos del volumen tridimensional al representar la intersección y la unión de los conjuntos. Esto permite capturar las similitudes y diferencias en el espacio tridimensional de manera eficiente. En lugar de comparar punto por punto los verdaderos positivos, falsos negativos y falsos positivos, Jaccard 3D considera la proporción entre la intersección y la unión de los volúmenes, es decir, la cantidad de elementos compartidos entre ambas máscaras en relación con la cantidad total de elementos presentes en al menos una de las dos máscaras. Este cambio de métrica es de gran rele-

vancia en nuestro contexto, ya que sería ineficiente y poco práctico evaluar píxel a píxel los resultados de verdaderos positivos, falsos positivos y falsos negativos cuando se trata de volúmenes tridimensionales. Para el cálculo de Jaccard 3D se obtuvo un valor de 0.352. Posteriormente, se hallaron los valores de precisión, cobertura y F-medida para el volumen original y el volumen de segmentación (ver tabla 2). Comparando las dos métricas, se evidencia una diferencia significativa lo que indica que el uso de métricas convencionales como la precisión y la cobertura podría ser inadecuado debido al desbalance de la base de datos explicado anteriormente. Estas métricas no tienen en cuenta la distribución desigual de las clases y pueden llevar a resultados incorrectos. Por ejemplo, si la mayoría de los píxeles pertenecen a estructuras que no sean el hígado, un modelo que prediga constantemente ‘no hígado’ podría alcanzar una alta precisión, pero esto no sería útil ni relevante para la tarea de segmentación del hígado. En este contexto, la métrica de Jaccard 3D es más adecuada y se adapta mejor a problemas con datos desbalanceados, ya que se centra en la superposición espacial entre las regiones de interés, independientemente de la prevalencia de una clase sobre la otra.

Precisión	Cobertura	F-medida
0.355	0.978	0.521

Table 2. Resultados precisión, cobertura y F-medida del modelo.

Como se ha mostrado anteriormente, para la segmentación del hígado mediante intensidades, hay muchos tejidos que tienen intensidades similares a nuestro órgano de interés lo que puede llevar a una mala segmentación y a una cantidad significativa de falsos positivos. Debido a lo anterior, se decidió umbralizar el volumen original y elegir el componente conexo más grande. En la Figura 6 se pueden ver los resultados de la umbralización y el elemento conexo máximo. Se puede observar que el resultado de la segmentación es mucho más claro y el modelo presenta menos problemas a la hora de diferenciar nuestro órgano de interés.




Figure 6. Resultados segmentación del hígado mediante elemento conexo.

Utilizando el mismo método mencionado anteriormente, se realizó una función que realizara el mismo tipo de segmentación, pero esta vez haciéndolo por cada slice en un recorrido axial. Los resultados para tres slices diferentes se pueden observar en la Figura 7.




Figure 7. Resultados segmentación por slice mediante elemento conexo.

Mediante la metodología de segmentación por elemento conexo se encontró el mejor umbral para obtener la mejor segmentación posible. En la Tabla 1 se pueden observar diferentes umbrales evaluados y su correspondiente índice de Jaccard. Teniendo en cuenta los resultados obtenidos, el mejor umbral encontrado fue de 0.85, el cual obtuvo un índice de Jaccard de 0.644.

Umbral	Índice de Jaccard
0.1	0.0
0.37	0.0
0.63	0.0
0.8	0.62
0.85	0.628
0.88	0.556
0.9	0.393

Table 3. Resultados Índice de Jaccard para diferentes umbrales utilizando el método de elemento conexo.

Posteriormente, se graficaron algunos resultados de la segmentación *groundtruth*, el mejor umbral (0.85) y un umbral peor (0.4) para obtener una comparación adecuada. Esto se graficó para 4 cortes axiales diferentes (ver Figura 8). De los resultados anteriores es posible concluir que la segmentación realizada con el mejor umbral se acerca a los resultados del *groundtruth*, aunque presenta una cantidad significativa de falsos positivos en los extremos del eje axial de hígado. Por otro lado, la segmentación realizada con un umbral peor da resultados bastante imprecisos, considerando muchas estructuras de manera incorrecta.

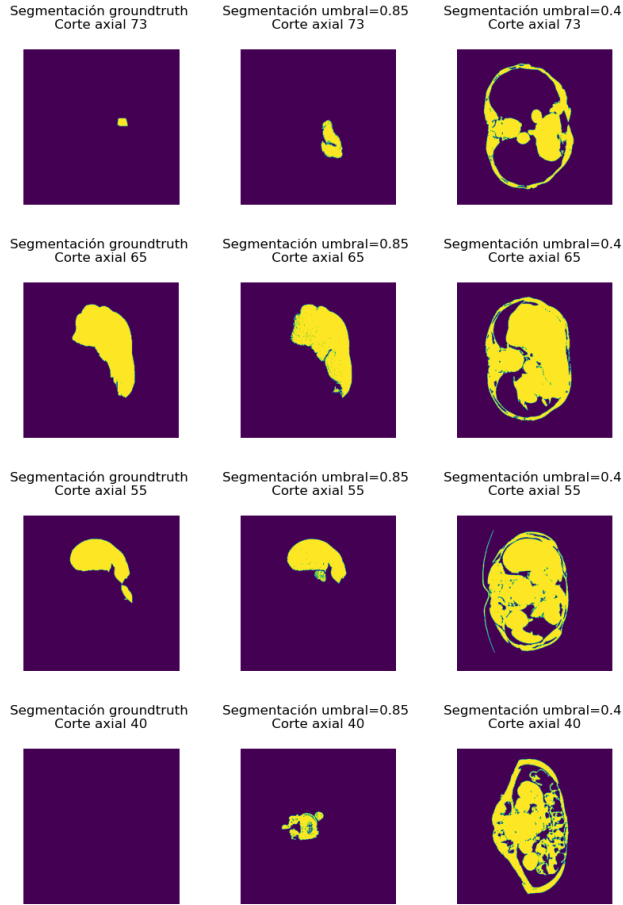


Figure 8. Resultados segmentación textitgroundtruth, umbral=0.85 y umbral=0.4.

Por último, se llevo a cabo la visualización de errores de nuestro modelo. Lo anterior con el objetivo de entender las limitaciones de nuestro modelo y así poder diseñar una metodología eficaz que mejore nuestros resultados y no nos resulte perjudicial. Para esto, se encontró el slice con más errores de cada eje (sagital, coronal, axial) y se graficó cada corte. Además, se graficaron los falsos positivos y falsos negativos por aparte de cada corte con más errores encontrado. Los resultados se pueden observar en la Figura 9.

Para mejorar los resultados de la segmentación del hígado mediante umbralización pura, se podría realizar una umbralización adaptativa de manera que no se utilice un umbral fijo y se halle un umbral que ajuste de forma local a las diferentes secciones de la imagen dependiendo de las características encontradas en cada región. Otra estrategia que podría ser utilizada sería la umbralización múltiple, en la que no se separarían las intensidades de la imagen en dos grupos, sino que se utilizarían múltiples umbrales para mejorar la precisión.

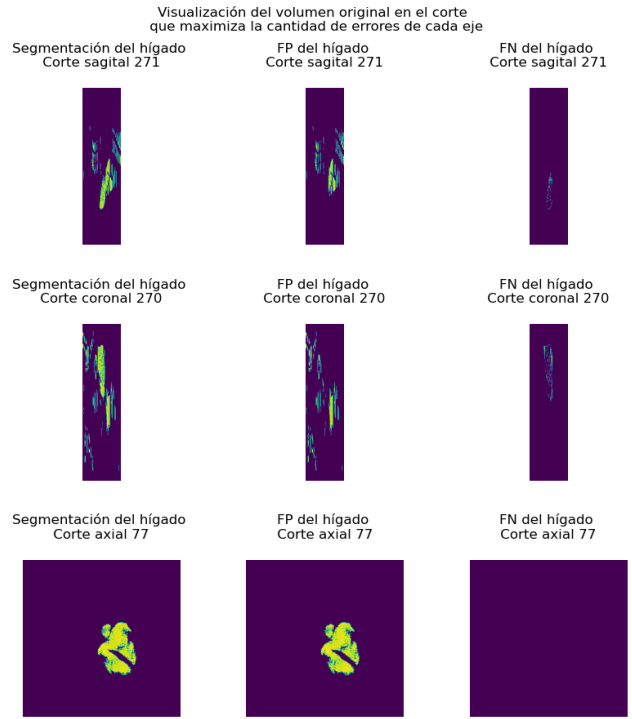


Figure 9. Resultados visualización de errores.

### 3. Conclusiones

El uso de la resonancia magnética para la obtención de imágenes médicas se ha vuelto de gran importancia en el ámbito médico, ya que permite visualizar estructuras internas del cuerpo con el propósito de diagnosticar enfermedades, monitorear tratamientos, entre otros. Debido a esto, la tarea de segmentación de imágenes médicas obtenidas por resonancia magnética a cobrado gran importancia, significando que este proceso de segmentación deba ser lo más eficiente y exacto posible.

Ahora, teniendo en cuenta que la manera en la que se obtienen este tipo de imágenes puede llevar a la perdida de claridad u obtención de ruido, es necesario procesar la base de datos con filtros, preferiblemente de naturaleza no lineal, que permitan reducir los impulsos en los niveles de gris de los píxeles sin llevar en una perdida de información de la imagen original. Posteriormente, se observó que para este tipo de segmentación es mejor utilizar métricas como la de Jaccard 3D que considere la unión y la intersección del volumen original y el volumen segmentado. Por otro lado, la segmentación del hígado basada en intensidades presenta desafíos debido a las similitudes en intensidades con otros tejidos, lo que puede resultar en una mala segmentación y falsos positivos. Se optó por la umbralización del volumen original y la selección del componente conexo más grande, lo que mejoró significativamente la claridad de la segmentación y la capacidad del modelo para identificar el hígado. Se realizó una exploración de umbrales y se encontró que un umbral de 0.85 ofreció el mejor índice de

Jaccard. Sin embargo, se observaron falsos positivos en los extremos del eje axial. Se visualizaron los errores del modelo para comprender sus limitaciones y trabajar en mejoras futuras.

## References

- [1] Mansilla Lucas and Ferrante Enzo. Segmentación multi-atlas de imágenes médicas con selección de atlas inteligente y control de calidad automático, 2018.
- [2] Forero Vargas Manuel Guillermo and Miranda Rojas Sergio Luis. Nuevo metodo para la estimacion de ruido gaussiano en imagenes biomedica, 2020.
- [3] NIH. Magnetic resonance imaging (mri), 2023.